

KLASIFIKACIJA ANTIMIKROBNIH PEPTIDA

1. Uvod

Antimikrobni peptidi (AMP) predstavljaju kratke lance aminokiselina koji imaju sposobnost uništavanja ili inhibiranja rasta različitih mikroorganizama, uključujući bakterije, gljivice i viruse. Oni su važan dio prirodnog obrambenog sustava organizama te imaju značajnu ulogu u istraživanjima novih antimikrobnih lijekova.

Razvojem bioinformatike i metoda strojnog učenja omogućena je analiza velikih količina bioloških podataka te predikcija različitih svojstava proteina i peptida. Jedan od takvih zadataka je razlikovanje antimikrobnih peptida od peptida koji nemaju antimikrobno djelovanje.

Cilj ovog projekta bio je razviti model strojnog učenja koji može klasificirati peptide na temelju njihovih sekvenci i izračunatih značajki. Projekt obuhvaća pripremu podataka, ekstrakciju značajki, treniranje modela te evaluaciju dobivenih rezultata.

2. Podaci i priprema podataka

Za potrebe projekta korišteni su podaci iz DBAASP baze podataka koja sadrži informacije o antimikrobnim peptidima i njihovim svojstvima. Iz baze su preuzete sekvence antimikrobnih peptida koje predstavljaju pozitivnu klasu.

Nakon učitavanja podataka provedeno je čišćenje sekvenci kako bi se uklonili neispravni zapisi i potencijalni duplikati. Budući da je za klasifikaciju potrebno imati dvije klase podataka, formiran je i skup neantimikrobnih peptida koji predstavlja negativnu klasu.

Nakon obrade podataka dobiven je uravnotežen skup podataka koji sadrži obje klase i spreman je za daljnju analizu.

3. Ekstrakcija značajki

Modeli strojnog učenja ne mogu izravno koristiti aminokiselinske sekvence pa je potrebno svaku sekvencu pretvoriti u skup numeričkih značajki.

Za svaki peptid izračunate su sljedeće značajke:

- duljina sekvence,

- neto naboj,
- hidrofobnost,
- molekularna masa,
- aromatičnost,
- izoelektrična točka.

Osim navedenih značajki izračunat je i aminokiselinski sastav (AAC), odnosno udio svake aminokiseline u sekvenci. Na taj način dobiven je detaljniji opis svakog peptida koji model može koristiti tijekom učenja.

Sve značajke spojene su u jedinstvenu matricu podataka koja je korištena za treniranje modela strojnog učenja.

4. Modeliranje

Nakon pripreme značajki podaci su podijeljeni na skup za treniranje i skup za testiranje u omjeru 80:20.

Za klasifikaciju su korištena dva modela strojnog učenja:

- Random Forest
- Support Vector Machine (SVM)

Random Forest temelji se na većem broju stabala odlučivanja koja zajednički donose konačnu odluku o klasifikaciji. Ovaj model često daje dobre rezultate na biološkim podacima te omogućuje procjenu važnosti pojedinih značajki.

Support Vector Machine (SVM) pokušava pronaći granicu koja najbolje razdvaja dvije klase podataka. Ovaj model poznat je po dobroj uspješnosti na problemima klasifikacije te je često korišten u bioinformatički.

5. Rezultati

Nakon treniranja modela provedena je evaluacija na testnom skupu podataka.

Random Forest model ostvario je točnost od približno 95 %, dok je SVM model ostvario točnost od približno 96 %. Oba modela pokazala su vrlo dobre rezultate klasifikacije te su uspješno razlikovala antimikrobne od neantimikrobnih peptida.

Za dodatnu analizu korištene su matrice zabune koje prikazuju broj ispravno i pogrešno klasificiranih primjera. Rezultati pokazuju da oba modela imaju mali broj pogrešnih klasifikacija.

Analiza važnosti značajki pokazala je da najveći doprinos klasifikaciji imaju svojstva povezana s duljinom sekvence, nabojem, hidrofobnošću i sastavom aminokiselina. Takvi rezultati u skladu su s poznatim biološkim svojstvima antimikrobnih peptida.

6. Zaključak

U ovom projektu razvijen je sustav za klasifikaciju antimikrobnih peptida korištenjem metoda strojnog učenja. Nakon pripreme podataka i izračuna značajki trenirani su Random Forest i SVM modeli te je provedena njihova evaluacija.

Dobiveni rezultati pokazali su da je moguće uspješno razlikovati antimikrobne peptide od neantimikrobnih na temelju njihovih sekvenci i izračunatih značajki. Najuspješnijim modelom pokazao se SVM koji je ostvario najveću točnost klasifikacije.

Projekt pokazuje kako se metode bioinformatike i strojnog učenja mogu koristiti za analizu bioloških podataka te predstavlja dobru osnovu za daljnja istraživanja u području predikcije svojstava peptida i proteina.